

Αναφορά για τη 2^η εργασία

Εισαγωγή

Στην εργασία αυτή συγκρινουμε τα αποτελέσματα της 1^{ης} εργασίας με αυτά της 2^{ης} όπου στην 1^η είχαμε χρησιμοποιήσει απλούς k-Nearest Neighbors (kNN) και Nearest Class Centroid (NCC) classifiers για τα datasets CIFAR10 και Breast Cancer. Παρατηρήσα, όμως, ότι το Breast Cancer δεν είναι multiclass dataset οπότε το αντικατέστησα με το [glass dataset](#) το οποίο θα περιγραφεί συντομα στην επομένη ενότητα.

Για κάθε dataset ακολουθήθηκε ενιαία πειραματική διαδικασία. Χρησιμοποιήθηκαν αρχικά απλά distance-based baselines (Nearest Neighbor / kNN και Nearest Class Centroid), εξεταστήκε η επίδραση της κανονικοποίησης/κλιμακώσης των χαρακτηριστικών και στη συνέχεια διερευνήθηκε μείωση διαστάσης πριν την ταξινόμηση. Στο CIFAR-10 χρησιμοποιήθηκαν HOG χαρακτηριστικά (ώστε να υπάρχει συνεπής σύγκριση με το 1^ο report, όπου είχαμε τα καλύτερα αποτελέσματα), ενώ στο Glass αξιοποιήθηκαν τα αρχικά αριθμητικά χαρακτηριστικά. Επιπλέον, εφαρμόστηκε συνδυασμός μη γραμμικής μείωσης διαστάσης με Kernel PCA και εποπτευομένης προβολής με LDA (KPCA+LDA) και αξιολογήθηκε η επίδραση του στον τελικό ταξινομητή (NN και NCC). Τα αποτελέσματα παρουσιάστηκαν με μετρικές accuracy και macro F1 και πραγματοποιήθηκε σύγκριση μεταξύ των διαφορετικών pipelines, ώστε να αναδειχθεί ο ρόλος της αναπαραστάσης και της μείωσης διαστάσης στην απόδοση και στην υπολογιστική αποδοτικότητα των ταξινομητών.

Glass Identification dataset

Το Glass Identification χρησιμοποιήθηκε ως δεύτερο case-study (μετά το CIFAR10 που περιγράφηκε στο προηγούμενο report), όπου η ταξινόμηση γίνεται σε τυπούς γυαλιού με βάση φυσικοχημικές μετρήσεις. Το dataset προέρχεται από την USA Forensic Science Service και έχει 214 δείγματα, με 9 πραγματικού τύπου χαρακτηριστικά (refractive index και ποσοστά οξειδίων Na, Mg, Al, Si, K, Ca, Ba, Fe), χωρίς missing values.

Οι κλάσεις ορίζονται ως τύποι γυαλιού (building windows, vehicle windows, containers, tableware, headlamps), με το class “vehicle_windows_non_float_processed” να αναφέρεται αλλά να μην υπάρχει στο dataset, άρα στην πράξη η ταξινόμηση γίνεται σε 6 ενεργές κλάσεις. Επίσης, το dataset προσφέρεται ήδη κλιμακωμένο στο [-1,1] και χρησιμοποιήθηκε 70/30 train/test split όπου μετά πήραμε stratified 5-fold cross validation.

Το Glass dataset παρουσιάζει ανισορροπία κλάσεων (βλ. figure 1), με ορισμένες κατηγορίες να έχουν σημαντικά λιγότερα δείγματα. Ως αποτέλεσμα, η accuracy μπορεί να υπερεκτιμήσει την απόδοση, ενώ η συμπεριφορά στις μικρές κλάσεις αποτυπώνεται καλύτερα με macro F1. Για το λόγο αυτό χρησιμοποιήθηκαν stratified splits και macro-averaged δείκτες, ώστε να αξιολογείται ισοτιμία κάθε κλάσης.




Figure 1 Αριθμός δειγμάτων ανα κλάση για train/test set.

KPCA+LDA

Η μείωση διαστάσης KPCA+LDA αποτελεί ένα pipeline που συνδυάζει μη-γραμμική προβολή και supervised dimensionality reduction, με σκοπό να παραχθεί ένας χαμηλοδιαστατός χώρος όπου οι κλάσεις είναι πιο ευκολα διαχωρίσιμες.

Στο πρώτο στάδιο, εφαρμόζεται Kernel Principal Component Analysis (KPCA). Σε αντίθεση με το κλασικό PCA που αναζητά γραμμικές κυρίες συνιστώσες, το KPCA χρησιμοποιεί ένα kernel για να χαρτογραφήσει τα δεδομένα σε έναν υψηλοδιαστατό χώρο χαρακτηριστικών, όπου μπορεί να αποτυπωθεί μη-γραμμική δομή. Στη συνέχεια, εκτελείται PCA σε αυτόν τον kernel-defined χώρο, με αποτέλεσμα να εξαχθούν μη-γραμμικές συνιστώσες οι οποίες διατηρούν μεγάλο μέρος της διακυμάνσης.

Στο δεύτερο στάδιο, εφαρμόζεται Linear Discriminant Analysis (LDA) πάνω στις συνιστώσες του KPCA. Το LDA είναι supervised μέθοδος προβολής που χρησιμοποιεί τα class labels ώστε να επιλέξει άξονες που μεγιστοποιούν τη διαχωρισιμότητα των κλάσεων (maximizing between-class variance while minimizing within-class variance). Σε πρόβλημα με C κλάσεις, το LDA παράγει το πολύ C-1 διαστάσεις (π.χ. 9 για το CIFAR-10 με 10 κλάσεις).

Ο συνδυασμός KPCA+LDA χρησιμοποιήθηκε ώστε να ληφθεί ένας χαμηλοδιαστατός χώρος χαρακτηριστικών. Το KPCA αποτυπώνει μη-γραμμικές συσχετίσεις και δομές στα δεδομένα, ενώ το LDA εκμεταλλεύεται τις ετικέτες για να “ευθυγραμμίσει” την προβολή προς τη μέγιστη δυνατή διαχωρισιμότητα. Με αυτό τον τρόπο, distance-based ταξινομητές όπως kNN και NCC μπορεί να βελτιωθούν, καθώς οι αποστάσεις υπολογίζονται σε χώρο με λιγότερες διαστάσεις και δυνητικά καλύτερη ταξική δομή.

Glass Identification

k-NN

Στο «απλό» k-NN (χωρίς επιπλέον μετασχηματισμούς/μείωση διαστάσης), πραγματοποιήθηκε grid search με scoring το macro F1 και εξεταστήκαν διάφοροι συνδυασμοί υπερπαραμετρών δηλαδή, αριθμός γειτονών $k = [1, 3, 5, 7, 9, 11, 15, 21]$, μετρική απόστασης euclidean και manhattan, δηλαδή L2 και L1 απόσταση και weighting scheme uniform (ισοβαρής συνεισφορά γειτονών) και distance (μεγαλύτερη βαρύτητα σε κοντινότερους γείτονες). Τα καλύτερα αποτελέσματα επιτεύχθηκαν για

k=3 με euclidean αποσταση και distance weighting, με μεση επιδοση macro F1 = 0.6621 (std = 0.1407). Συνολικα, παρατηρηθηκε οτι μικρες τιμες του k (ιδιαιτερα k=3) και η χρηση distance weighting τεινουν να αποδιδουν καλυτερα, ενω οι χρονoi εκπαιδευσης και προβλεψης ειναι χαμηλοι (mean fit time ~0.002 s ανα fold) αφου προκειται για ένα μικρο dataset με μολις 214 samples.

#	metric	k (n_neighbors)	weights	mean macro F1	mean fit time (s)	mean score time (s)
0	euclidean	3	distance	0.6621	0.002427	0.011350
1	euclidean	3	uniform	0.6550	0.002302	0.012939
2	manhattan	3	distance	0.6538	0.001732	0.005831
3	manhattan	5	distance	0.6487	0.002075	0.006877
4	manhattan	1	uniform	0.6396	0.001671	0.006997

KPCA+LDA

Στο pipeline **KPCA+LDA + kNN** πραγματοποιηθηκε εκτεταμενο grid search, ωστε να διερευνηθει ο συνδυασμος μη γραμμικης μειωσης διαστασης (KPCA), εποπτευομενης προβολης (LDA) και ταξινομησης με kNN. Συγκεκριμενα, εξεταστηκαν πολλα διαφορετικα σετ υπερπαραμετρων ως εξης:

- **Διαστασεις KPCA (kpca__n_components):** δοκιμαστηκαν οι τιμες [2, 3, 5, 7, 9], ωστε να ελεγχθει ποσο μπορει να συμπιεστει η αναπαρασταση πριν χαθει χρησιμη πληροφορια.
- **Αριθμος συνιστωσων LDA (lda__n_components):** για καθε επιλογη KPCA διαστασεων, επιλεχθηκαν επιτρεπτες τιμες $1..min(kpca_n, n_classes-1)$ (δηλαδη $lda_n_components \leq min(kpca_n, lda_cap)$), ωστε το LDA να εφαρμοζεται σωστα και να μεγιστοποιει τη διαχωριστικη ικανοτητα στον μειωμενο χωρο.

Για το KPCA δοκιμαστηκαν δυο kernels:

1. **RBF kernel (KPCA-RBF)**
 - kpca__gamma: [0.1, 0.5, 1.0, 2.0, 5.0]
 - kpca__n_components: [2, 3, 5, 7, 9]
2. **Polynomial kernel (KPCA-Poly)**
 - kpca__gamma: [0.1, 0.5, 1.0]
 - kpca__degree: [2, 3]
 - kpca__coef0: [0.0, 1.0]
 - kpca__n_components: [2, 3, 5, 7, 9]

Παραλληλα, για τον τελικο **kNN classifier** εξεταστηκαν:

- clf__n_neighbors: [1, 3, 5, 7, 9, 11, 15, 21]
- clf__metric: ["euclidean", "manhattan"]
- clf__weights: ["uniform", "distance"]

Η αξιολογηση του grid search εγινε με **scoring = macro F1**, ωστε να δοθει ισοβαρης βαρυτητα σε ολες τις κλασεις και για καθε συνδυασμο υπερπαραμετρων πραγματοποιηθηκε 5-fold cross validation (δηλαδη ο χωρος δεδομενων χωριστηκε σε 5 folds, με ενα fold να χρησιμοποιειται καθε φορα ως validation και τα υπολοιπα 4 ως training), ωστε να προκυψει πιο σταθερη και αξιοπιστη εκτιμηση της επιδοσης.

Με βαση τα αποτελεσματα, η καλυτερη ρυθμιση (rank 1) επιτευχθηκε με **KPCA-RBF** (gamma = **0.1**, n_components = **7**) και **LDA n_components = 4**, σε συνδυασμο με **kNN (k=7, euclidean, distance weighting)**, με μεση επιδοση **macro F1 = 0.6815** (std = **0.1285**). Επισης, παρατηρηθηκε οτι αρκετες απο τις κορυφαιες λυσεις εντοπιστηκαν γυρω απο **KPCA n_components = 7** και σχετικα χαμηλες τιμες gamma, ενω σε ορισμενες περιπτωσεις ανταγωνιστικες επιδοσεις καταγραφηκαν και με polynomial kernel (degree 2).

#	clf metric	k	weights	KPCA kernel	gamma	n_components (KPCA)	n_components (LDA)	degree	coef0	mean macro F1	mean fit time (s)	mean score time (s)
0	euclidean	7	distance	rbf	0.1	7	4	—	—	0.6815	0.01	0.007
1	euclidean	1	uniform	poly	0.1	7	5	2	1.0	0.6736	0.006	0.006
2	euclidean	1	distance	poly	0.1	7	5	2	1.0	0.6736	0.010	0.006
3	manhattan	5	distance	poly	0.1	7	4	2	1.0	0.6726	0.009	0.008
4	manhattan	3	distance	rbf	0.1	7	4	—	—	0.6720	0.009	0.007

Σε συγκριση με το απλο kNN χωρις μειωση διαστασης, παρατηρηθηκε μικρη βελτιωση. Συγκεκριμενα, στο baseline kNN (χωρις KPCA+LDA) επιτευχθηκε macro F1 = 0.6621, ενω με το pipeline KPCA+LDA + kNN η καλυτερη ρυθμιση του grid search εδωσε macro F1 = 0.6815. Γεγονος που υποδεικνυει οτι η μειωση διαστασης παρηγαγε εναν χωρο χαρακτηριστικων οπου οι αποστασεις γειτονιας αξιοποιουνται πιο αποτελεσματικα απο τον kNN.

NN

Στο απλο Nearest Class Centroid (NCC) εφαρμοσαμε grid search για την επιλογη των καλυτερων υπερπαραμετρων. Συγκεκριμενα, εξετασαμε:

- **metric:** euclidean, manhattan
- **shrink_threshold:** None, 0.05, 0.1, 0.5, 1.0

Ο ταξινομητης ηταν ο NearestCentroid(), και η αναζητηση πραγματοποιηθηκε με GridSearchCV, χρησιμοποιωντας ως μετρικη αξιολογησης το **macro F1** (scoring="f1_macro"), ωστε να δοθει ισοβαρης βαρυτητα σε ολες τις κλασεις. Η αξιολογηση εγινε με 5 fold **cross-validation**. Με

αυτές τις ρυθμίσεις έχουμε top score την χαμηλή τιμή 0.55 όπως βλέπουμε και στον πίνακα.

Ran k	metric	shrink_thresho ld	mean_test_sco re	mean_fit_ti me (s)	std_fit_ti me	mean_score_ti me (s)
1	manhatta n	0.05	0.5557	0.002263	0.000337	0.004116
2	manhatta n	None	0.5484	0.002659	0.000350	0.005139
3	manhatta n	0.1	0.5425	0.002722	0.000938	0.005430
4	manhatta n	0.5	0.5227	0.002928	0.000671	0.005011
5	euclidean	0.5	0.5125	0.002694	0.000611	0.004979

KPCA+LDA

Όπως και πριν χρησιμοποιήθηκε grid search, ώστε να επιλεγούν οι βελτιστοί συνδυασμοί υπερπαραμετρών για τη μη-γραμμική μείωση διαστάσης (KPCA), την εποπτευόμενη προβολή (LDA) και την τελική ταξινόμηση (NCC).

Η αναζήτηση εκτελέστηκε πάνω στις διαστάσεις:

- `kpca_dims = [2, 3, 5, 7, 9]`

Για κάθε τιμή από το `kpca_dims`, οι επιτρεπτές τιμές του `lda__n_components` καθορίστηκαν με βάση τον θεωρητικό περιορισμό:

- **LDA `n_components` $\leq \min(n_features_entering_LDA, n_classes - 1)$**

Στη συνέχεια, το grid ορίστηκε για δύο kernels του KPCA:

1) KPCA με RBF kernel

Για κάθε `kpca_n` δοκιμάστηκαν:

- `kpca__gamma`: [0.1, 0.5, 1.0, 2.0, 5.0]
- `clf__metric`: ["euclidean", "manhattan"]
- `clf__shrink_threshold`: [None, 0.05, 0.1, 0.5, 1.0]

2) KPCA με Polynomial kernel

Για κάθε `kpca_n` δοκιμάστηκαν:

- `kpca__gamma` : [0.1, 0.5, 1.0]
- `kpca__degree`: [2, 3]
- `kpca__coef0`: [0.0, 1.0]
- `clf__metric`: ["euclidean", "manhattan"]
- `clf__shrink_threshold`: [None, 0.05, 0.1, 0.5, 1.0]

Στον πίνακα αποτελεσμάτων παρατηρήθηκε ότι οι 3 πρώτες διαμορφώσεις (rank 1) είχαν το ίδιο mean_test_score (0.6318), γεγονός που δείχνει ότι η απόδοση ήταν ουσιαστικά ισοδυναμη μεταξύ αυτών των επιλογών. Η ισοβαθμία προκύψε επειδή τα pipelines ήταν ίδια σε KPCA (RBF, gamma=0.1, n_components=9) και LDA (n_components=4), ενώ άλλαζε μόνο το `shrink\_threshold`, το οποίο δεν επηρέασε μετρησιμα την απόδοση σε αυτό το επίπεδο cross-validation.

Ο NCC υπολογίζει ένα centroid για κάθε κλάση και ταξινομεί ένα δείγμα με βάση την απόσταση του από αυτά τα centroids. Με το shrink_threshold, εφαρμόζεται shrinkage / soft-thresholding στα centroids. Για κάθε χαρακτηριστικό, η διαφορά του κεντροειδούς μιας κλάσης από τον συνολικό μέσο όρο “συρρικνώνεται” προς το 0. Αν η διαφορά είναι μικρή, μπορεί να γίνει ακριβώς 0 μετά το thresholding. Έτσι, χαρακτηριστικά που δεν ξεχωρίζουν ουσιαστικά τις κλάσεις “απενεργοποιούνται”.

#	clf_metric	shrink_threshold	kpca_kernel	kpca_gamma	kpca_n_components	lda_n_components	mean_test_score	rank	mean_fit_time (s)	mean_score_time (s)
0	euclidean	None	rbf	0.1	9	4	0.6318	1	0.008	0.005261
1	euclidean	0.05	rbf	0.1	9	4	0.6318	1	0.008	0.006058
2	euclidean	0.1	rbf	0.1	9	4	0.6318	1	0.009	0.006261
3	euclidean	0.1	rbf	0.1	9	5	0.6241	4	0.009	0.006447
4	euclidean	None	rbf	0.1	9	5	0.6238	5	0.006	0.004448

Σε σύγκριση με την ανάλυση χωρίς μείωση διαστάσεων, όπου επιτεύχθηκε macro F1 = 0.5557, με το pipeline KPCA + LDA επιτεύχθηκε σαφώς καλύτερη απόδοση, με macro F1 = 0.6318. Δηλαδή καταγράφηκε αύξηση κατά 0.0761 (περίπου +13.7% σχετική βελτίωση), κάτι που δείχνει ότι η μη-γραμμική προβολή του KPCA και η εποπτευόμενη συμπίεση του LDA παρήγαγαν πιο διαχωριστικό χώρο χαρακτηριστικών για τον NCC σε σχέση με τα αρχικά χαρακτηριστικά.

CIFAR-10

KPCA+LDA

Αρχικά χρησιμοποιήθηκε μικρό subset για ταχεία διερεύνηση (150 train ανά κλάση, συνολικά 1500 train, και 50 test ανά κλάση, συνολικά 500 test), ώστε να περιοριστεί το κόστος των grid searches. Εξαχθηκαν **HOG χαρακτηριστικά** από τις εικόνες και προκύψε διάνυσμα χαρακτηριστικών διαστάσης **324**. Για το KPCA ορίστηκε gamma baseline ως 1/324 και παραχθηκε gamma grid ως κλιμακώσεις αυτής της τιμής: [0.5*gamma_base, gamma_base, 2*gamma_base, 5*gamma_base],

οπου $base = 1 / n_features(HOG)$ και $n_features = 324$.

Πραγματοποιήθηκε **grid search για KPCA (RBF)** με pipeline StandardScaler -> KPCA -> LDA -> NCC, όπου:

- ο δοκιμαστήκαν `kpca__n_components` απο {32, 64, 128}
- ο δοκιμαστήκαν `kpca__gamma` απο {0.0015432, 0.0030864, 0.0061728, 0.0154321}
- ο χρησιμοποιήθηκε **3-fold CV** με scoring **accuracy**

Επιλεχθηκαν ως καλύτερες τιμες: **`kpca__n_components = 128`** και **`kpca__gamma = 0.0061728`**, με καλύτερη accuracy ~ **0.45**.

Στη συνέχεια εφαρμόστηκε ο καλύτερος StandardScaler -> KPCA(best) -> LDA, και παραχθηκαν τελικά χαρακτηριστικά διαστάσης **9** (λόγω LDA με $n_components=9$).

Αφου πραγματοποιήθηκε η μείωση διαστάσης, αξιολογήθηκαν οι ταξινομητες:

- Για **kNN** πραγματοποιήθηκε grid search (3-fold CV, scoring accuracy) με:
 - `n_neighbors` απο {1, 3, 5, 7, 9, 11}
 - `metric` απο {euclidean, manhattan}
 - `weights` απο {uniform, distance}
 - ως καλύτερος συνδυασμός επιλεχθηκε: **`metric=euclidean, n_neighbors=11, weights=uniform`**
 - στο subset μετρήθηκαν: **accuracy = 0.4620** και **macro F1 = 0.4609**
- Για **NCC (NearestCentroid)** πραγματοποιήθηκε grid search (3-fold CV, scoring accuracy) με:
 - `metric` απο {euclidean, manhattan}
 - `shrink_threshold` απο {None, 0.05, 0.1, 0.5, 1.0}
 - ως καλύτερος συνδυασμός επιλεχθηκε: **`metric=euclidean, shrink_threshold=0.5`**
 - στο subset μετρήθηκαν: **accuracy = 0.5100** και **macro F1 = 0.5158**

Τελος, πραγματοποιήθηκε εφαρμογή στο **πληρες CIFAR-10** με τους καλύτερους υπερπαραμετρους. Εξαχθηκαν HOG χαρακτηριστικά για ολο το train/test (50k/10k). Για λογους αποδοτικότητας, το **KPCA εκπαιδευτηκε σε subset** και στη συνέχεια έγινε transform σε ολο το train/test, ενώ το **LDA εκπαιδευτηκε στο πληρες train** (στον KPCA-χωρο). Με τους βελτιστους ταξινομητες πανω στις μειωμενες αναπαραστασεις μετρήθηκαν:

- BEST kNN**: test **accuracy = 0.4969**, **macro F1 = 0.4971** (predict time σημαντικά μεγάλο)
- BEST NCC**: test **accuracy = 0.5051**, **macro F1 = 0.5064** (πολυ γρηγορο prediction)

Συνολικά, η διερεύνηση οργανώθηκε σε δυο σταδια (subset tuning και full run) και τεκμηριώθηκε ότι η αλυσίδα **HOG -> KPCA -> LDA** παρήγαγε συμπαγεις αναπαραστασεις, στις οποίες ο NCC παρουσίασε ελαφρώς καλύτερη αποδοση και σαφώς καλύτερη ταχύτητα inference σε σχέση με τον kNN.

Τα αποτελέσματα από το προηγούμενο report ήταν:

Μοντελο	Best params	Χρονος fit (sec)	Test accuracy	Test macro F1
kNN σε HOG full	algorithm = auto, metric = manhattan, n_neighbors = 9, weights = distance	0.01	0.5435	0.5356
NCC σε HOG full	metric = manhattan, shrink_threshold = None	0.40	0.4084	0.4034

Η βελτιωση απο τη μειωση διαστασης με KPCA+LDA φανηκε να βελτιωνει κυριως τον **NCC**, ενω για τον **kNN** η καλυτερη συμπεριφορα καταγραφηκε οταν ταξινομηθηκε απευθειας στο HOG χωρο χωρις επιπλεον προβολες. Όμως στις μειωμενες διαστασεις η ταχυτητα του training και prediction είναι σαφεστατα πιο γρηγορη.

Συγκριση SVM – KPCA+LDA

Στο CIFAR-10, η SVM analysis κατεληξε οτι το ισχυροτερο αποτελεσμα επιτυγχανεται οταν τα SVMs εκπαιδευονται σε HOG χαρακτηριστικα, και συγκεκριμενα με RBF kernel στο full dataset. Σε αυτο το setup, αναφερεται test accuracy 0.6366 και test macro F1 0.6364 (με train time 1203.82 sec για την εκδοση με C=150, gamma=scale), ενω η εκδοση με C=10 δινει test accuracy 0.6362 και macro F1 0.6360. Επιπλεον, σε raw pixels στο full dataset, ο polynomial SVC degree 3 φτανει test accuracy 0.5244 και macro F1 0.5254, ενω το LinearSVC δινει χαμηλοτερα (test accuracy 0.3854, macro F1 0.3707).

Αντιθετα, στο report του KPCA+LDA η συγκριση γινεται κυριως με distance-based μοντελα (kNN και NCC) πανω σε συμπαγεις αναπαραστασεις που παραγονται απο HOG -> KPCA -> LDA. Στο full dataset, με το KPCA+LDA pipeline βρεθηκε για το NCC test accuracy 0.5051 και test macro F1 0.5064, ενω για το kNN test accuracy 0.4969 και macro F1 0.4971. Με βαση αυτες τις μετρικες το καλυτερο SVM σε HOG υπερτερει καθαρα των KPCA+LDA αποτελεσματος, ενω το KPCA+LDA προσφερει κυριως ενα ανταγωνιστικοτερο και υπολογιστικα πιο “ελαφρυ” μοντελο για NCC/kNN, οχι ομως καλυτερο απο το kernel SVM πανω σε HOG.

Συνολικα, **καλυτερο για τελικη αποδοση** ειναι το **SVM σε HOG με RBF**, ενω **καλυτερο για γρηγορο και απλο inference** ειναι το **KPCA+LDA + NCC** μοντελο, με την παραδοχη οτι γινεται αποδεκτη λιγο χαμηλοτερη αποδοση σε accuracy/macro F1.

Συζητηση

Στη διερευνηση εξεταστηκε αν η μειωση διαστασης με KPCA+LDA μπορει να βελτιωσει απλους ταξινομητες αποστασης, οπως ο kNN και ο Nearest Class Centroid. Στο dataset Glass παρατηρηθηκε οτι η συνδυαστικη προβολη KPCA+LDA οδηγησε σε πιο «καθαρο» χωρο χαρακτηριστικων και γενικα σε πιο σταθερη και καλυτερη συμπεριφορα σε σχεση με την προσεγγιση χωρις dimensionality reduction. Επιπλεον, στον πινακα αποτελεσματος του grid search φανηκε οτι οι κορυφαιες ρυθμισεις ειχαν πρακτικα ισοδυναμη αποδοση, κατι που υποδηλωνει οτι ορισμενες

υπερπαραμετροι επηρεαζαν πολύ λιγο τα αποτελεσματα, αφου καθορισθηκαν οι βασικες επιλογες του KPCA και του LDA.

Στο CIFAR-10 η εικονα ηταν πιο μικτη. Ο NCC ωφεληθηκε αισθητα απο το KPCA+LDA, καθως η συμπιεση και ο διαχωρισμος υπερ-χωρος ενισχυσαν την ταξινομηση με κεντροειδη, ενω παραλληλα διατηρηθηκε πολυ γρηγορο inference. Αντιθετα, ο kNN εδειξε οτι μπορει να προτιμα πιο «πλουσιο» χωρο χαρακτηριστικων χωρις επιπλεον προβολες, επειδη βασιζεται ισχυρα σε τοπικες σχεσεις γειτονιας που μπορει να αλλοιωθουν απο μεγαλη μειωση διαστασης. Συνολικα, η μειωση διαστασης φανηκε να ταιριαζει περισσοτερο σε centroid-based μοντελα, ενω ο kNN διατηρει πλεονεκτημα οταν παραμενει περισσοτερη λεπτομερεια στην αναπαρασταση, αλλα με το αναμενομενο κοστος σε χρονο προβλεψης.