

Αναφορά για τη 3^η εργασία

Εισαγωγή

Στο παρόν report μελετάται **unsupervised clustering** στο CIFAR-10 με μια ενιαία, graph-based προσέγγιση: (i) μετατροπή κάθε εικόνας σε feature vector, (ii) κατασκευή similarity graph και παραγωγή χαμηλοδιαστατής αναπαράστασης (**2D embedding**) με μεθόδους manifold learning / kernel methods, και (iii) εφαρμογή **Spectral Clustering** στον embedded χώρο.

Τα labels δεν χρησιμοποιούνται στην εκπαίδευση, αλλά μόνο εκ των υστέρων για external evaluation (NMI/ARI). Τέλος, εξετάζεται και μια πρακτική διαδικασία “μεταφοράς” σε test set με centroid-based assignment, ώστε να φανεί αν τα clusters έχουν σταθερή/ερμηνευσιμή δομή και εκτός του train subset.

Metrics

Στην αξιολόγηση των αποτελεσμάτων χρησιμοποιήθηκαν δύο κατηγορίες metrics, αναλογα με το αν μετράμε “καθαρα” την ποιότητα του clustering ή αν θέλουμε να το μετατρέψουμε σε πρακτική κατηγοριοποίηση στο test set.

(A) Unsupervised / external validation metrics (για clustering):

Τα βασικά metrics ήταν τα **NMI** και **ARI**, τα οποία συγκρίνουν τα predicted cluster IDs με τα ground-truth labels, χωρίς όμως να απαιτούν ευθυγράμμιση των cluster labels με τις κλάσεις.

- **NMI (Normalized Mutual Information):** μετρά ποση πληροφορία μοιράζονται οι clusters με τις πραγματικές κλάσεις. Τιμές κοντά στο 0 σημαίνουν ασθενή συσχέτιση, ενώ μεγαλύτερες τιμές δείχνουν ότι οι clusters ευθυγραμμίζονται καλύτερα με τα labels. Είναι χρήσιμο όταν θέλουμε να δούμε αν το clustering βρήκε συμβατή δομή με τις κλάσεις.
- **ARI (Adjusted Rand Index):** μετρά συμφωνία σε επίπεδο ζευγών δειγμάτων: αν δύο δείγματα είναι στην ίδια κλάση, είναι και στο ίδιο cluster (και αντιστρόφως). Το “adjusted” σημαίνει ότι διορθώνει για τυχαία συμφωνία, οπότε το 0 αντιστοιχεί σε τυχαίο clustering και τιμές προς 1 σημαίνουν ισχυρή συμφωνία.

(B) Classification-style metrics (για test transfer):

Όταν εφαρμόζεται η centroid-based αναθεση στο test και γίνεται mapping cluster->class με majority vote όπως περιγράφεται παρακάτω, το clustering μεταφράστηκε σε predicted labels και υπολογίστηκαν:

- **Accuracy:** ποσοστό σωστων προβλεψεων στο test.
- **Macro-F1:** ο μέσος όρος του F1-score ανά κλάση (ισοβαρής συνεισφορά κάθε κλάσης). Είναι πιο καταλλήλο όταν θέλουμε να δούμε αν το μοντέλο αποδίδει ομοιομορφα σε όλες τις κλάσεις και να εντοπίσουμε περιπτώσεις όπου κάποιες κλάσεις αγνοούνται (π.χ. κλάσεις με μηδενικές προβλεψεις).

CIFAR-10

Το CIFAR-10 είναι ιδιαίτερα απαιτητικό για unsupervised clustering επειδή οι κλάσεις είναι **semantic** (π.χ. cat/dog/airplane) και η ομοιότητα σε raw pixel space κυριαρχείται από low-level cues (χρώμα, φωτισμός, background, textures). Επομένως, το κρίσιμο ζήτημα είναι αν οι graph/manifold embeddings μπορούν να παραγουν μια αναπαράσταση όπου οι τοπικές γειτονίες (neighbors) αντανάκλουν καλύτερα την οπτική/σημειολογική ομοιότητα.

Μεθοδολογία CIFAR-10

Η ανάλυση ξεκινά με την επιλογή ενός stratified subset (ίσα δείγματα ανά κλάση) του CIFAR 10, ώστε να μειωθεί το υπολογιστικό κόστος και να ελεγχεται η class-balance. Στη συνέχεια, κάθε εικόνα μετατρέπεται σε feature vector (raw pixels ή HOG) και γίνεται scaling με StandardScaler (fit στο train subset, transform σε train/test) για να σταθεροποιηθούν οι αποστάσεις και η κατασκευή του kNN graph (similarity graph). Πάνω σε αυτό το feature space εφαρμόζονται διάφορες τεχνικές για εξαγωγή 2D embeddings, με στόχο να αποτυπωθεί η τοπική δομή του similarity graph σε δύο διαστάσεις. Στον embedded χώρο εφαρμόζεται SpectralClustering με affinity graph από nearest neighbors και k-means assignment. Τα labels χρησιμοποιούνται μόνο για να μετρηθεί ποσο “ταιριαζουν” clusters και κλάσεις με NMI/ARI.

Για να εκτιμηθεί η σταθερότητα των clusters και η δυνατότητα “μεταφοράς” τους σε νέα δείγματα (test set), ακολουθείται μια διαδικασία που εξασφαλίζει ότι train και test θα βρεθούν στον ίδιο 2D χώρο. Συγκεκριμένα, αρχικά ενώνονται τα scaled features του train και του test (concatenation) και εφαρμόζεται pipeline **KPCA** -> **t-SNE** στο σύνολο, ώστε να προκύψει ένα κοινό 2D embedding για όλα τα δείγματα. Αυτό επρέπε να γίνει γιατί αν τρεχαμε t-SNE ξεχωριστά σε train και test, οι δύο 2D χαρτες δεν θα ήταν συγκρίσιμοι (θα είχαν διαφορετική γεωμετρία).

Αφού από το grid search βρήκα ότι το t-SNE είναι η καλύτερη μέθοδος για 2D διαχωρισμό, έκανα ένα επιπλέον βήμα ώστε να βελτιώσω τη σταθερότητα και την “ποιότητα” των neighborhoods που βλέπει το t-SNE. Συγκεκριμένα, εφαρμόσα πρώτα Kernel PCA (KPCA) για να μειώσω τη διάσταση σε 50 και μετά ξανατρεξά t-SNE πάνω σε αυτή τη συμπιεσμένη αναπαράσταση. Η λογική είναι ότι το CIFAR-10 (και ακόμα και το MNIST σε μικρότερο βαθμό) περιέχει θόρυβο και πολλές διαστάσεις που δεν συμβάλλουν ουσιαστικά στη semantic/μορφολογική ομοιότητα, οπότε το KPCA λειτουργεί σαν ένα μη γραμμικό “denoising + compression” βήμα.

Αφού παραχθεί το κοινό embedding, διαχωρίζονται εκ νέου οι 2D συντεταγμένες σε **Z_train** και **Z_test**. Στη συνέχεια, το **clustering εκτελείται αποκλειστικά στο Z_train**, με SpectralClustering, ώστε η δομή των clusters να προκύψει μόνο από “γνωστά” δείγματα (χωρίς να επηρεαστεί από το test). Με βάση τις train cluster αναθεσεις, υπολογίζονται **centroids ανά cluster** στον 2D χώρο, δηλαδή ο μέσος όρος των 2D συντεταγμένων των train σημείων που ανήκουν στο κάθε cluster. Αυτά τα centroids λειτουργούν ως “representatives” των clusters και επιτρέπουν μια απλή, διαδικασία αναθεσης για το test.

Για κάθε test δειγμα, υπολογίζεται η απόσταση του από όλους τους train centroids (Euclidean distance στο 2D embedding) και το δειγμα ανατιθεται στο cluster του κοντινότερου centroid. Έτσι προκύπτουν cluster IDs για το test set, χωρίς να ξανατρεξει ο clustering αλγοριθμος στο test και χωρίς να χρησιμοποιηθουν labels.

Τελος, για να μπορεσει να υπολογιστει η αποδοση με supervised metrics (accuracy, macro-F1), γινεται μια ερμηνευτικη αντιστοιχιση **cluster -> class label** βασισμενη μονο στο train: για καθε cluster, λαμβανεται η πλειοψηφικη κλαση (majority vote) απο τα ground-truth train labels των δειγματων που ανηκουν σε αυτο το cluster. Αυτη η αντιστοιχιση εφαρμοζεται επειτα στα test cluster IDs, μετατρεποντας τα σε predicted class labels, και υπολογιζονται **accuracy** και **macro-F1** στο test. Το macro-F1 χρησιμοποιειται για να δωσει ισοβαρη βαρυτητα σε ολες τις κλασεις και να φανει αν το clustering αποδιδει ομοιομορφα η αν “ευνοει” συγκεκριμενες κλασεις εις βαρος αλλων.

Παραμετροι

- Dataset: CIFAR-10 (10 classes)
- Subset sizes: train = 2000, test = 500 (stratified)
- Representations: raw pixels (3072 dims) και HOG (324 dims)
- Scaling: StandardScaler (fit στο train subset, transform σε train/test)
- HOG params: orientations=9, pixels_per_cell=(8,8), cells_per_block=(2,2), block_norm="L2-Hys"
- 2D embedding methods: Spectral Embedding, Isomap, LLE, t-SNE, KPCA (RBF/Polynomial), LPP
- SpectralClustering: affinity="nearest_neighbors", assign_labels="kmeans"
- Grid: n_neighbors ∈ {5, 10, 15}, n_clusters ∈ {8, 9, 10, 11}, tsne_perplexity ∈ {20, 30, 40}
- Evaluation: NMI (Normalized Mutual Information), ARI (Adjusted Rand Index)
- Test transfer: train centroids + nearest-centroid assignment, majority-vote mapping, metrics: accuracy και macro-F1

Αποτελεσματα

Raw pixels

- Best (train external): t-SNE + SpectralClustering με NMI ~ 0.095 και ARI ~ 0.037

- Test (centroid assignment): accuracy ~ 0.214 και macro-F1 ~ 0.187




Figure 2 Clusters στα train data vs Ομάδες από Labels




Figure 1 True labels vs predicted and centroid στο σύνολο ελέγχου

HOG features

- Best (train external): NMI ~ 0.159 και ARI ~ 0.075

- Test (centroid assignment): accuracy ~ 0.20 και macro-F1 ~ 0.15




Figure 3 Clusters στα train data vs Ομάδες από Labels σε HOG features

Συμπεράσματα

Τα αποτελέσματα δείχνουν ότι στο CIFAR-10 το representation καθορίζει σε μεγάλο βαθμό την ποιότητα του similarity graph. Σε raw pixels οι γειτονίες δεν φαίνεται να είναι aligned με semantic similarity, άρα το SpectralClustering δεν έχει “σωστή” πληροφορία για να ανακτήσει σημειολογικές ομάδες. Η μεταβαση σε HOG βελτιώνει το local structure και ανεβαζει NMI/ARI στο train, αλλά η συνολική μεταφορά στο test παραμένει αδύναμη, κάτι που υποδηλώνει ότι τα clusters δεν αντιστοιχούν σταθερά σε semantic partitions. Επιπλέον, ο περιορισμός σε 2D (ιδίως με t-SNE) είναι χρήσιμος για visualization, αλλά φαίνεται να αλλοιώνει την δομή και να κάνει δύσκολη μια μη επιβλεπόμενη μεθοδολογία μάθησης.

MNIST

Στο MNIST εφαρμόζω την ίδια λογική όπως και στο CIFAR-10, αλλά με μία διαφορά. Στο MNIST τα δεδομένα είναι grayscale digits (28×28) και η δομή στο **pixel space** είναι πιο “καθαρή” με λιγότερο background clutter και πιο συνεπείς μορφολογίες ανά κλάση. Επομένως, αναμένεται ότι τα embeddings και ειδικά μεθοδοί τύπου **t-SNE** θα παράγουν πιο διαχωρισμένες ομάδες σε σχέση με CIFAR-10.

Επίσης, δεν εφαρμόζω HOG, διότι στο MNIST η πληροφορία ακμών/gradients είναι ήδη έντονα παρούσα στο raw signal και η βελτίωση δεν είναι τόσο μεγάλη όσο σε φυσικές εικόνες.

Αφού βρω πάλι την καλύτερη μέθοδο με τις καλύτερες παραμέτρους (πάλι t-SNE είναι) το ξανατρέχω με KPCA αλλά αυτή την φορά το ρίχνω στις 30 διαστάσεις.

Μεθοδολογια MNIST

Η ροη παραμενει:

raw pixels → scaling → 2D embedding → SpectralClustering,

με grid search σε $n_neighbors$, $n_clusters$ και για t-SNE perplexity. Οπως και πριν, τα labels χρησιμοποιουνται μονο για external evaluation (NMI/ARI).

Παραμετροι

- Dataset: MNIST (10 digits)
- Shapes: $X_train=(60000,784)$, $X_test=(10000,784)$
- Subset sizes: train = 2000, test = 500 (stratified)
- Representation: raw pixels (784 dims)
- Scaling: StandardScaler (fit στο train subset, transform σε train/test)
- Grid: method $\in \{\text{spectral_embedding, lpp, isomap, lle, tsne, kpca_rbf, kpca_poly}\}$, $n_neighbors \in \{5,10,15\}$, $n_clusters \in \{8,9,10,11\}$, $tsne_perplexity \in \{20,30,40\}$
- Evaluation: NMI, ARI
- Test transfer: KPCA -> t-SNE (train+test), train clustering, centroids, nearest-centroid assignment

Αποτελεσματα

- Best by NMI (train): method=t-SNE, $n_neighbors=10$, $tsne_perplexity=40$, $n_clusters=8$, ARI=0.4403, NMI=0.5921
- Best με $n_clusters=10$ (train): method=t-SNE, $n_neighbors=15$, $tsne_perplexity=20$, $n_clusters=10$, ARI=0.3870, NMI=0.5892




Figure 4 Clusters στα train data vs Ομαδες απο Labels




Figure 5 True labels vs predicted and centroid στο συνολο ελεγχου.




Figure 6 Confusion matrix του test set.

Συμπερασματα

Τα αποτελεσματα στο MNIST δειχνουν οτι το συγκεκριμενο pipeline (raw pixels + StandardScaler + 2D embedding + Spectral Clustering) μπορεί να ανακτησει σημαντικό μέρος της δομής των δεδομένων σε unsupervised setting, σαφώς καλύτερα από ο,τι στο CIFAR-10. Οι υψηλότερες τιμές NMI/ARI υποδηλώνουν οτι οι τοπικές γειτονίες στο pixel space είναι πιο meaningfully aligned με τη μορφολογία των digits, με αποτέλεσμα μεθοδοι όπως t-SNE να παραγουν embeddings με σχετικά καθαρή ομαδοποίηση.

Συνολικά, στο MNIST το pipeline είναι ισχυρό ως unsupervised exploratory εργαλείο και για ποιοτική/ποσοτική αξιολόγηση της δομής, αλλά για πιο robust downstream ανάθεση σε νέα δείγματα συχνά απαιτείται embedding σε υψηλότερες διαστάσεις ή πιο σταθερή out-of-sample στρατηγική.

Συμπεράσματα και συγκριτική συζήτηση (MNIST vs CIFAR-10)

Συγκριτικά, το MNIST εμφανίζει σαφώς καλύτερο unsupervised signal από το CIFAR-10 στο ίδιο framework, επειδή οι τοπικές γειτονίες στο pixel space είναι πιο σταθερές και σχετίζονται περισσότερο με τη μορφολογία του digit, με αποτέλεσμα οι embeddings (ιδίως t-SNE) να παραγουν πιο συνεκτικές δομές και υψηλότερα NMI/ARI. Επίσης, οι εικόνες στο MNIST είναι εύκολο να τις διακρίνει ένας αλγόριθμος γιατί εκτός από grayscale φαίνεται ξεκάθαρα που ξεκινάει η γραμμή του αριθμού. Δηλαδή έχει μικρό θόρυβο σε αντίθεση με το CIFAR dataset.

Αντιθέτως, στο CIFAR-10 η semantic κατηγορία δεν προκύπτει εύκολα από low-level features (ακόμα και με HOG), λόγω μεγάλης ποικιλίας και semantic gap. Επιπλέον, ο περιορισμός σε 2D ευνοεί την οπτικοποίηση αλλά φαίνεται να χάνουμε σημαντική πληροφορία